

Proyecto: Predicción de precipitación con el uso de variables climáticas

1. Extracción de datos:

Para el análisis de datos, se extrajeron los registros de la base de datos del SIATA, centrándonos específicamente en la estación meteorológica ubicada en la torre Siata debido a su amplio conjunto de datos, tratamiento previo y fiabilidad. Las variables seleccionadas para este estudio incluyen la Humedad Relativa, Temperatura, Presión Atmosférica, Radiación, Velocidad y Dirección del Viento, así como la Precipitación. Los datos recopilados abarcan desde el 1 de enero de 2018 hasta el 28 de febrero de 2023. Para su análisis, se agruparon tomando la media horaria, con excepción de la precipitación, donde se tomó la suma de los valores de cada hora. A continuación, se presenta una descripción general del conjunto de datos a utilizar.

	Temperatura	Presion	Humedad	VeloViento	DireViento	Radiacion	Precipitacion
fecha							
2018-01-01 00:00:00	18.605000	849.493333	78.423333	2.918333	6.966667	NaN	0.0
2018-01-01 01:00:00	18.110000	848.941667	78.426667	1.953333	10.200000	NaN	0.0
2018-01-01 02:00:00	17.688333	848.656667	79.396667	1.005000	18.083333	NaN	0.0
2018-01-01 03:00:00	17.135000	848.238333	81.558333	1.133333	12.533333	NaN	0.0
2018-01-01 04:00:00	17.368333	848.398333	79.163333	0.726667	12.966667	0.0	0.0
...	...	...	...	...	...	...	...
2023-02-28 19:00:00	24.288333	846.723333	64.780000	5.110000	7.433333	NaN	0.0
2023-02-28 20:00:00	23.381667	847.721667	68.931667	4.776667	6.916667	NaN	0.0
2023-02-28 21:00:00	22.451667	848.585000	76.561667	4.641667	7.750000	NaN	0.0
2023-02-28 22:00:00	22.018333	848.576667	78.955000	4.503333	9.566667	NaN	0.0
2023-02-28 23:00:00	21.926667	848.816667	76.646667	3.676667	7.283333	NaN	0.0

45240 rows × 9 columns


Para eliminar los outliers, se tomaron los datos mayores a un percentil 3 y menor que el percentil 99. De esta manera obtenemos un dataset con 45240 filas.

2. Valores faltantes e interpolación

El dataset presenta una cantidad significativa de valores nulos, a continuación, se encuentra el número de valores faltantes por variable:

Temperatura	1681
Presion	1789
Humedad	1756
VeloViento	1492
DireViento	1492
Radiacion	18426

Para llenar los valores faltantes se hará uso de “NeuralProphet”, una librería de Python diseñada para el análisis y el ajuste de series temporales univariantes utilizando técnicas de deep learning. A continuación, se muestra un gráfico que ilustra el ajuste de la serie temporal de la presión atmosférica mediante esta herramienta.



3. Adición de característica: precipitación pasada

Dado que la variable de precipitación muestra una correlación significativa debido a un retardo temporal, resulta conveniente generar una nueva columna de datos que tome en cuenta esta característica. Por lo tanto, en una fila de datos que contiene la fecha y hora 2023-02-28 21:00:00, la columna "Precipitación pasada" reflejará el total de precipitación registrado durante la hora anterior, es decir, durante el intervalo de tiempo que abarca desde las 2023-02-28 20:00:00.

4. Adición de característica: Hora del día


Al observar modelos meteorológicos fundamentados en principios físicos, se identificó que un aspecto crucial de la precipitación es su relación con la hora del día. En diversas ubicaciones del planeta, se ha observado una tendencia recurrente de la precipitación en momentos específicos del día. Con base en este hallazgo, se ha generado una nueva columna que considera estos patrones temporales.

5. Modelos de ajuste:

Queremos encontrar un modelo que sea capaz de predecir la precipitación haciendo uso exclusivo de las variables climáticas. Por ende, normalizaremos el dataset y lo dividiremos en datos de entrenamiento y datos de test, con una relación 9-1 (90% datos de entrenamiento, 10% datos de test). Los diferentes modelos de regresión usados se describen a continuación:


A. Regresión lineal

Para el modelo de regresión lineal se obtuvo una train score de 0.28 y un test score de 0.26.



B. Random Forest Regression

Con el uso del random forest regression se obtuvo un train score de 0.67 y un test score de 0.33.




Con estos datos se puede realizar una matriz de confusión:

El numero de verdaderos positivos(evento de lluvia predicho como lluvia) del modelo: 89
El numero de falsos negativos(evento de lluvia no predicho como lluvia) del modelo: 17
El numero de falsos positivos(evento sin lluvia predicho como lluvia) del modelo: 111
El numero de verdaderos negativos(evento sin lluvia predicho como sin lluvia) del modelo: 5

C. Gradient Boosted Trees


Haciendo uso de gradient Boosted trees se obtuvo un test score de 0.707



La matriz de confusión es la siguiente:

El numero de verdaderos positivos(evento de lluvia predicho como lluvia) del modelo: 154
El numero de falsos negativos(evento de lluvia no predicho como lluvia) del modelo: 43
El numero de falsos positivos(evento sin lluvia predicho como lluvia) del modelo: 79
El numero de verdaderos negativos(evento sin lluvia predicho como sin lluvia) del modelo: 4405

La importancia de las características es:




Como se puede observar, el mejor modelo está teniendo en cuenta en gran medida la precipitación pasada, la segunda y tercera características más importantes son la temperatura y humedad. Por tanto, haciendo uso de este modelo podemos predecir la precipitación con un 70% de confiabilidad a una hora a futuro de la hora actual.


6. Entendiendo las características

Queremos entender cómo se comportan las variables cuando existe un evento de lluvia, y así entender cómo nuestro modelo pesa las características a la hora de hacer una predicción. Para ello, tomaremos el dataset y lo filtraremos, tomaremos únicamente los datos que tengan una precipitación acumulada en 1 hora mayor o igual que 1.5, haciendo esto obtenemos los 222 eventos de mayor precipitación. Nos interesa examinar el comportamiento de la serie temporal de cada variable hasta 8 horas antes de que ocurra el evento de precipitación. De esta manera, buscamos identificar si existe alguna relación entre estas series temporales y si muestran un patrón similar antes de la ocurrencia de un evento de lluvia.

A. Humedad





Hacemos una media de estas series de tiempo y encontramos las barras de error:



A la izquierda se puede visualizar la gráfica que describe el comportamiento medio de la serie de tiempo de humedad 8 horas de que ocurra y a la derecha los valores para construir el área de error.



B. Temperatura

Usando el mismo procedimiento encontramos el comportamiento de las series de tiempo de las demás variables





t	xmin	xmax
0	21.941668	26.495291
1	21.805222	26.205914
2	21.229127	25.601495
3	20.578758	24.736940
4	19.978659	23.909119
5	19.215160	22.959984
6	18.509206	21.771406
7	17.835846	20.635371
8	17.428319	19.443752

C. Presión atmosférica



t	xmin	xmax
0	844.491148	847.896848
1	844.256006	847.264632
2	844.429280	846.913403
3	844.699816	847.033464
4	845.098853	847.671519
5	845.652354	848.566748
6	846.427264	849.476306
7	847.399200	850.107723
8	848.137129	850.375487

D. Velocidad del viento



t	xmin	xmax
0	1.371898	3.857054
1	1.585567	4.067548
2	1.533776	4.347570
3	1.371509	4.474181
4	1.172902	4.300395
5	1.126264	4.241608
6	1.122119	4.171277
7	0.966289	3.838160
8	0.607001	3.247753

7. Filtrando usando las barras de error

Luego de generar las barras de error de los datos podemos usarlas para predecir un evento de lluvia. Como primero usaremos las barras de error generadas en el evento de precipitación, es decir, en la hora 0 en las gráficas.

Estas series de tiempo cambian dependiendo del rango del día en el que esten, es decir, el comportamiento de las series de tiempo para eventos de lluvia entre las 12-18 son diferentes a las series de tiempo para eventos de lluvia entre las 0-6, por tanto, haremos esta distinción en los dataset.

Usaremos las barras de error creadas con anterioridad para filtrar los datos en el conjunto de datos y luego crearemos nuevas columnas denominadas "Counts". Estas


columnas indicarán si la variable a analizar se encuentra dentro de los rangos establecidos por las barras. Por ejemplo, "CountsP" indicará si la medición de la presión atmosférica está dentro de los rangos de error definidos anteriormente. Si es así, se asignará el valor 1; de lo contrario, se asignará el valor 0. Este proceso se repetirá para la humedad ("CountsH"), la temperatura ("CountsT") y la velocidad del viento ("CountsV"). A continuación, se muestra cómo se verá el conjunto de datos después de aplicar este proceso de filtrado mediante el uso de las barras.

fecha	Temperatura	Presion	Humedad	VeloViento	DireViento	Radiacion	Precipitacion	P2	fecha.1	fecha	Hora	CountsT	CountsP	CountsH	CountsV	SumCounts
2018-01-01 00:00:00	18.605000	849.493333	78.423333	2.918333	6.966667	NaN	0.0	0.0	2018-01-01 00:00:00	2018-01-01 00:00:00	0	1	0	1	1	3
2018-01-01 01:00:00	18.110000	848.941667	78.426667	1.953333	10.200000	NaN	0.0	0.0	2018-01-01 01:00:00	2018-01-01 01:00:00	1	1	0	1	1	3
2018-01-01 02:00:00	17.688333	848.656667	79.396667	1.005000	18.083333	NaN	0.0	0.0	2018-01-01 02:00:00	2018-01-01 02:00:00	2	0	0	1	0	1
2018-01-01 03:00:00	17.135000	848.238333	81.558333	1.133333	12.533333	NaN	0.0	0.0	2018-01-01 03:00:00	2018-01-01 03:00:00	3	0	0	1	0	1
2018-01-01 04:00:00	17.368333	848.398333	79.163333	0.726667	12.966667	0.0	0.0	0.0	2018-01-01 04:00:00	2018-01-01 04:00:00	4	0	0	1	0	1

“SumCounts” nos dice si el dato tiene más de una variable en la que se encuentra en las barras de error.


A. Eventos de lluvia entre las 12-18h:

Analizando los datos se encontró que la mayor cantidad de eventos de lluvia se producía entre las 12-18h, por tanto, el primer análisis lo haremos sobre estos datos. Haremos un histograma sobre todo el dataset con aquellos datos que cumplan SumCounts=3, es decir, que tenga 3 variables entre las barras y además son considerados eventos de lluvia.



Las barras azules representan los datos de presión, la naranja la temperatura, la verde la velocidad del viento y la roja la humedad.

Y un nuevo histograma con variables que cumplen SumCounts=3 pero no son considerados eventos de lluvia.



Como se puede observar, durante un evento de lluvia, las variables con mayor probabilidad de encontrarse dentro de los rangos establecidos por las barras son la presión, la temperatura y la humedad. Sin embargo, se observa que la temperatura es la que más frecuentemente cae dentro de estos rangos cuando se registran mayores niveles de precipitación. Por otro lado, la velocidad del viento muestra que, a pesar de la ocurrencia de eventos de precipitación, los datos correspondientes rara vez cumplen con las condiciones definidas por las barras para la velocidad del viento.

Basándonos en estas observaciones, proponemos una nueva condición para predecir un evento de precipitación entre las 12:00 y las 18:00 horas. Para que se considere un evento de precipitación durante este período, los valores de presión atmosférica, temperatura y humedad deben encontrarse dentro de los siguientes intervalos:

t	xmin	xmax
Temperatura	17.830884	21.282708
Presion	845.477056	848.185062
Humedad	67.265864	86.226156
VeloViento	1.135724	3.586223


Evaluemos esta condición, impongamos que se cumplan estas 3 condiciones sobre todo el dataset y observemos cuantos eventos de lluvia encontramos. Se identificaron

366 eventos que cumplen las tres condiciones y coinciden con eventos de lluvia, mientras que 591 eventos que cumplen las tres condiciones no se clasifican como eventos de lluvia. En total, existen 1100 eventos de lluvia entre las 12:00 y las 18:00 horas.


B. Eventos entre las 0-6

Los histogramas para estos valores son:

Eventos de lluvia:



Para eventos que no son de lluvia:



Los intervalos entre los que deben estar las variables para que exista evento de lluvia entre las 0-6h:


	t	xmin	xmax
Temperatura		17.101450	18.858889
Presion		847.606473	849.584702
Humedad		79.271319	90.730605
VeloViento		0.509460	2.913352

Evaluemos esta condición, impongamos que se cumplan estas 3 condiciones sobre todo el dataset y observemos cuantos eventos de lluvia encontramos. Se identificaron 375 eventos que cumplen las tres condiciones y coinciden con eventos de lluvia, mientras que 1567 eventos que cumplen las tres condiciones no se clasifican como eventos de lluvia. En total, existen 1503 eventos de lluvia entre las 12:00 y las 18:00 horas.


C. Eventos entre 6-12h:

Los histogramas para estos valores son:

Eventos de lluvia:



Para eventos que no son de lluvia:



Los intervalos entre los que deben estar las variables para que exista evento de lluvia entre las 6-12h:


t	xmin	xmax
Temperatura	17.091851	19.779825
Presion	848.756671	850.795142
Humedad	73.659557	89.542936
VeloViento	0.591970	2.713226

Evaluemos esta condición, impongamos que se cumplan estas 3 condiciones sobre todo el dataset y observemos cuantos eventos de lluvia encontramos. Se identificaron 96 eventos que cumplen las tres condiciones y coinciden con eventos de lluvia, mientras que 1128 eventos que cumplen las tres condiciones no se clasifican como eventos de lluvia. En total, existen 385 eventos de lluvia entre las 6 y las 12 horas.


D. Eventos entre 18-23h:

Los histogramas para estos valores son:

Eventos de lluvia:



Para eventos que no son de lluvia:



Los intervalos entre los que deben estar las variables para que exista evento de lluvia entre las 18-23h:

	t	xmin	xmax
Temperatura	17.421328	19.636631	
Presion	847.950816	850.309715	
Humedad	76.605176	89.922524	
VeloViento	0.688699	3.461693	

Se identificaron 372 eventos que cumplen las tres condiciones y coinciden con eventos de lluvia, mientras que 835 eventos que cumplen las tres condiciones no se clasifican como eventos de lluvia. En total, existen 1232 eventos de lluvia entre las 18 y las 23 horas.

